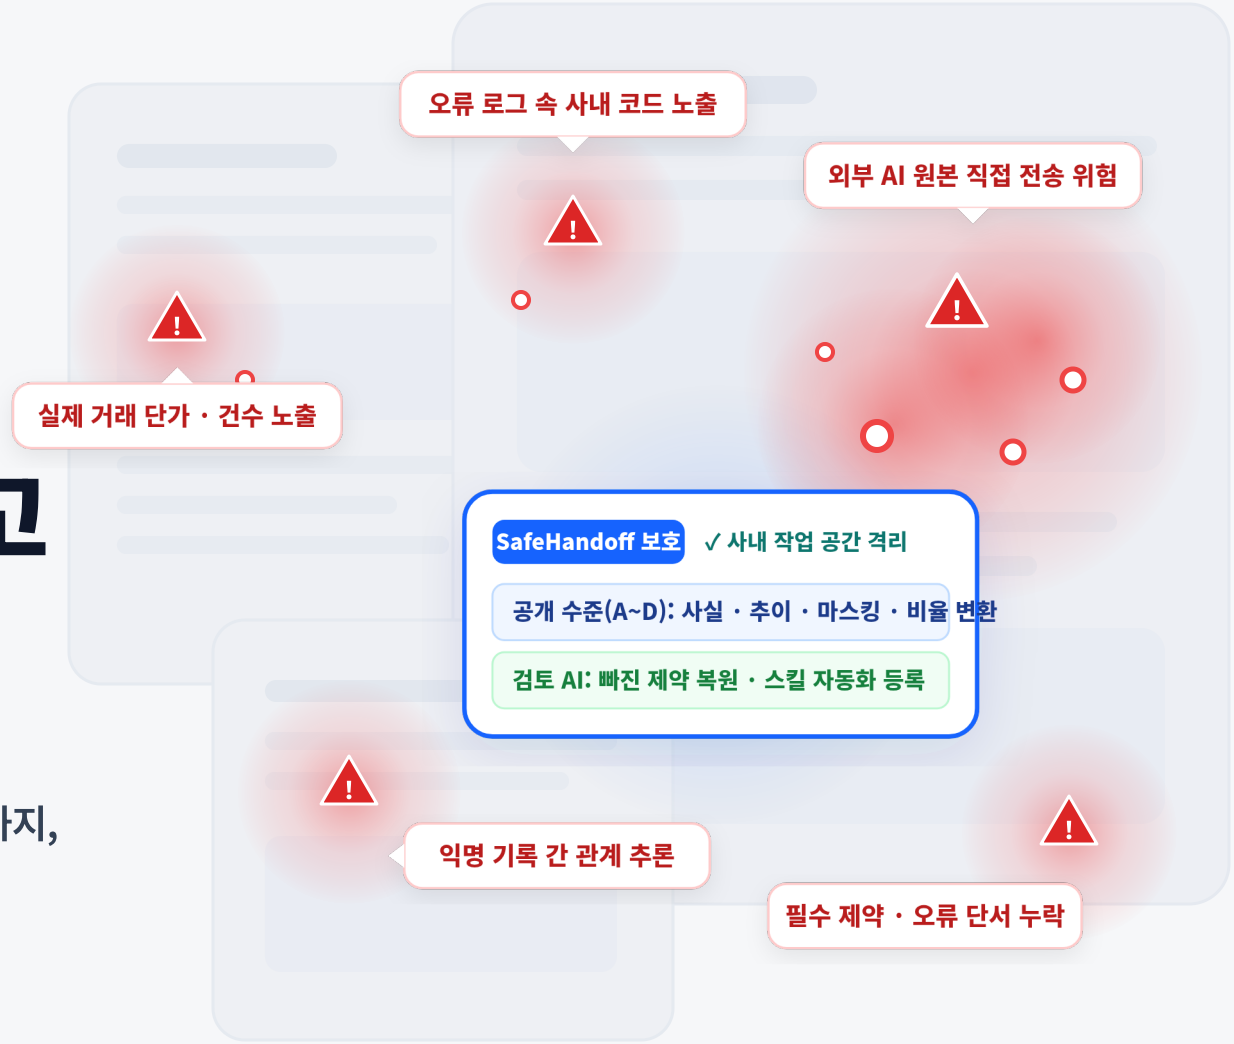
Codyssey

CODYSSEY HACKATHON TEAM PROJECT

SafeHandoff

외부에 공유할 사내 자료, 민감 정보는 안전하게 가리고 필요한 단서만 전달하세요



제품 목표 소개 · 현재 구현/계획/보장 표현은 실제 구현 · 발표 이슈 참조

공개 수준(A~D) 맞춤 선택부터 작성·검토 AI 이중 검증·스킬 자동화까지,
원본 유출 걱정 없이 외부 문의·자문 자료를 완성하는 사내 AI 솔루션

지피한테물어봐 김병철 이상혁 맹주영 김민성 임재홍

CONTENTS

INDEX

SafeHandoff · 오류는 보여주고 내부 정보는 덜 보이게, 사내 AI 기반 공유 자료 준비 도구

WHY
왜 이 문제인가

01 프로젝트 배경

WHO
누구를 위해

02 타겟 페르소나

03 서비스 플로우

HOW
어떻게 작동하나

04 기술 스택

05 AI 기술 및 개발 범위

06 서비스 아키텍처

07 서비스 차별점

NEXT
기대 가치와 확장

08 기대효과

09 확장 가능성

10 팀원 소개

프로젝트 배경: 외부에 물어야 일은 풀리는데, 그대로 보내면 유출이 된다

실제 보안 사고 뉴스와 기업 데이터 반출 조사에서 확인한 세 가지 배경

배경 1 · 현실의 기밀 유출 사고

급한 오류·회의록을 외부에 묻다 회사 기밀이 유출된다


[단독] 우려가 현실로…삼성전자, 챗GPT 빗장 풀자마자 '오남용' 속출

정두용 기자
입력 2023.03.30 18:20 수정 2023.03.30 20:35

가 글자크기 공유 인쇄 URL복사 댓글

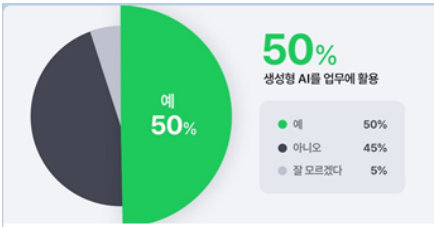
반도체 사업장 챗GPT 허용 20일, 정보 유출 사고 3건 발생
설비 계측·수율 데이터, 미국 기업에 고스란히 전송…회수 불가
필요시 해당 임직원 징계…사내 전용 AI 서비스 구축 검토

회사 데이터 외부 AI 입력 1년 새 485% 폭증
삼성전자 반도체 부문 코드·회의록 유출 3건 발생

- 당장 급한 오류를 고치려 **소스코드 전체를 복붙**하고, **비공개 회의록**을 통째로 넣어 요약을 맡겼다가 핵심 기밀이 외부 서버로 유출됨

배경 2 · 막아도 쓰게 되는 현실

유출이 두려워 회사에서 막아도, 당장 급한 직원은 몰래 복붙한다



이스트시큐리티, 보안 담당자 200명 설문…"AI 민감 정보 유출 우려 커"
www.aitimes.com

기업 보안 우려 1위 '민감 정보 유출'(64.5%)
하지만 개인 계정으로 몰래 쓰는 비율은 73.8%

- 외부에 가장 많이 복붙하는 자료는 ① **고객지원 문의 (16.3%)** ② **소스코드(12.7%)** ③ **내부 문서 (10.8%)** 순으로, 회사에서 막아도 일을 해결하려 몰래 보내게 됨

배경 3 · 이름만 가리는 방식의 한계

이름·번호만 지워선 비밀이 새고, 너무 많이 지우면 대화가 안 된다



"문맥은 살리고 개인정보만 가린다"
서울대 이재진 교수팀, AI 비식별화 개발
www.snu.ac.kr

덜 가리면 주변 내용으로 회사 정보가 드러나고
너무 많이 가리면 앞뒤 맥락이 깨져 이해 불가

- 이름·연락처만 가리면 **주변 내용과 합쳐져 회사 정보가 드러나고**, 반대로 너무 많이 지우면 **앞뒤 맥락이 끊기며 사람이 일일이 찾아 고치는 데 큰 시간**이 듦

타겟 페르소나: 외부에 도움을 청할 때마다, 회사 자료를 일일이 가리고 다시 쓰느라 지친 실무자



서비스 운영·기술지원 담당 · 핵심 사용자

박지훈 31세 · 남

IT 서비스 기업 운영·기술지원 담당 (4년 차)

회사 보안 때문에 **외부 AI·고객센터에 원본 첨부 금지**

매달 **외부 업체에 오류 문의·업무 자문**을 요청함

보내야 할 자료: **업무 현황표 · 회의 메모 · 오류 화면**

가려야 할 정보: **거래처 이름 · 단가 · 건수 · 회사 코드**

원본 첨부 금지 | 일일이 손으로 가림 | 매달 외부 문의

> “외부에 물어봐야 당장 막힌 일이 풀리는데, 원본을 그대로 보내면 보안 사고고 하나하나 지우다 보면 설명이 빠져서 두세 번씩 다시 써야 해요.”

페인 포인트 (Pain Points)

- **[손으로 가리는 시간 낭비]** 회사 파일을 외부 AI나 고객센터에 그대로 보낼 수 없어, **사람이 일일이 거래처·숫자·주소를 찾아 지우고 문장을 새로 쓰느라 시간을 다 쓴다**
- **[이름만 지워도 티 나는 회사 비밀]** 이름·전화번호만 가려도 **오류 기록의 작업 이름이나 단가 비율에서 우리 회사의 영업 방식과 규모가 드러날까 봐** 어디까지 보여줄지 매번 고민한다
- **[너무 많이 지우면 대화가 안 됨]** 겁이 나서 숫자와 설명을 다 지워버리면, **정작 상대방이 오류를 확인하지 못하거나 중요한 조건(“기존 접수 채널 유지”)을 놓쳐서** 두세 번 다시 설명해야 한다
- **[고칠 때마다 반복되는 수작업]** 로그를 고칠 때마다 **관련된 설명 내용도 일일이 맞춰서 다시 수정해야 하고**, 다음번에 비슷한 로그를 보낼 때도 처음부터 똑같은 작업을 반복한다

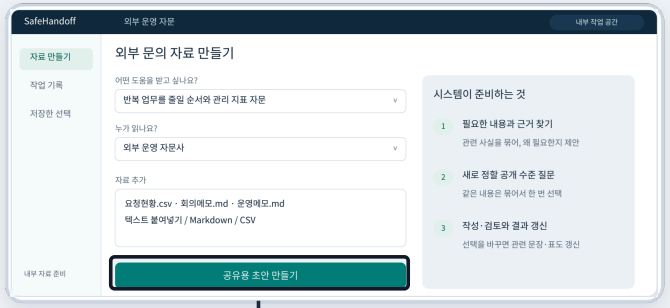
니즈 및 목표 (Needs & Goals)

- **[수준만 고르면 알아서 가림]** 원본은 회사 안에서만 읽고, **어디까지 보여줄지 공개 수준(A~D)만 고르면 AI가 알아서 일정 부분을 가려주면 좋겠다**
- **[AI 수정 로그를 사람이 확인]** AI가 가려야 할 부분을 가린 **‘수정 로그’를 만들어 보여주면, 제대로 가려졌는지 사람이 한눈에 확인하고 싶다**
- **[규칙 보완 및 로그·설명 수정]** 부정확하면 **사람이 규칙을 수정·추가해 다시 돌리고, 정확하면 로그 파일과 그에 관한 설명 내용까지 한꺼번에 수정**되면 좋겠다
- **[스킬 등록으로 다음 작업 자동화]** 확인이 끝난 처리 기준(어떤 경우에 어느 정도로 가릴지)을 **‘스킬(Skill)’에 등록해 두고, 다음번에는 자동으로 처리하고 싶다**

외부 공유 자료 준비 User Flow

설계 목표·후속 계획 포함 · 현재 완료 범위는 실제 구현 · 발표 이슈 참조

01. 외부 문의 자료 만들기 (목적 · 수신처 · 내부 자료 입력)



[공유용 초안 만들기] 버튼을 누른다

02. 공개 수준(A~D) · 규칙 설정 ("어느 수준으로 유지할까요?")



공개 수준 선택 후 진행

공개 수준 선택 방식 (A~D)

A · B · C 기본 보기 선택

(사실만 / 추이만 / 마스킹)

03-1. A · B · C 선택 결과 (A 사실만 · B 추이만 · C 요청 정보 마스킹)



작성·검토 AI 초안 완성
+ 빠진 제약("채널 유지") 복원

D 기타(직접 입력) 선택
"첫 관찰=100 비율만 보여줘"



[이 조건으로 작성] 클릭



05. [결과가 맞다면] 공유본 전달 및 스킬(자동화) 등록

① **수정된 로그 · 본문 · 표 최종 확정 및 저장**
가려진 결과와 관련 설명 내용을 함께 반영해 [복사 / 다운로드]

② **스킬(Skill) 등록으로 다음 작업 자동화**
'어떤 경우에 어느 정도로 가릴지' 처리 기준을 스킬에 기록·저장

③ **다음 작업 시 목적 · 상대 · 조건 확인 후 재사용**
같은 조건이면 자동 적용 · 목적이 달라지면 다시 질문

05. 최종 저장 및 스킬 등록 (04번 확인 결과가 맞을 때 진행)

03-2. D 기타(직접 입력) (조건 입력 → 실제 비율 확인 → 이 조건으로 작성)

04. 선택한 공개 수준에 따른 최종 결과 (B 선택 예시 · 사람 최종 확인)

↺ [정확하지 않다면 → 02번 복귀] 규칙을 수정·추가하거나 공개 수준을 다시 설정

✓ [결과가 맞다면 → 다음 단계(05)] 복사·다운로드 후 가림 규칙을 스킬(Skill)에 등록

핵심 기술 Core Technology & Stack

현행 아키텍처 · 미연결 기능은 계획으로 표기

프론트엔드 Client · View

HTML / CSS / TypeScript

HTML·CSS 화면과 TypeScript 동작을 사용합니다. 현재 연결은 내부 메모 저장·조회와 코어 상태 확인입니다.

CSS · 작업 화면

직접 작성한 CSS와 시스템 글꼴을 사용합니다. 공개 방식 카드는 표현 설명이며 실제 공개 결과 계산은 후속입니다.

선택 상태 · 갱신 계획

현재는 A~D 선택과 직접 입력을 화면에 유지합니다. 본문·표·설명 동시 갱신은 API 연결 후 구현할 계획입니다.

내부 근거 · 반출 계획

문장별 원자료 근거 표시와 최종 파일 확인·다운로드는 계획입니다. 현재 UI에서 성공으로 표시하지 않습니다.

백엔드 & AI 엔진 Controller · AI Engine

Node HTTP / TypeScript

pnpm workspace의 app이 HTTP server와 RealCore를 조립합니다. server는 Core 계약에만 의존합니다.

호환 HTTP ModelClient

설정한 OpenAI 호환 endpoint에 호출합니다. 모델별 기능과 품질은 실제 연결 시험으로 확인합니다.

FactPack · builtin 변환

승인된 FactPack으로 새 초안을 작성합니다. 결정적 변환과 grounding 검증을 구현했으며 전체 원자료 처리 흐름은 후속입니다.

LLM 검토 · grounding

현재 초안·FactPack·grounding을 검토합니다. 원자료 분석과 전체 3자 의미 대조·누락 제약 복원은 계획입니다.

데이터베이스 & 인프라 Model · DevOps

SQLite / node:sqlite

문서 저장·조회와 내부 task/decision 저장을 구현했습니다. task/decision HTTP API와 UI 연결은 후속입니다.

Rule / SkillPack 구분

Rule은 공개 결정의 재사용 데이터, SkillPack은 제품 지침·도구 팩입니다. 팩 로딩·ToyRecord 연결은 구현했고 Rule 매칭은 후속입니다.

실행 경계 · Docker

고정 digest의 toy 이미지를 격리 실행합니다. 앱 인증·전체 원자료 작업 환경 격리는 후속이며 기업별 내부 운영이 기준입니다.

mise / pnpm / QG

Node 24·pnpm·TypeScript와 just check로 타입·빌드·테스트를 검사합니다. PR Preview·자동 배포는 계획입니다.

* 기술·구현 근거: architecture · README · API

설계 원칙: 승인 정보로 새 작성 · 실제 구현과 계획 구분

핵심 AI 파이프라인 및 직접 개발 범위

설계 목표·후속 계획 포함 · 현재 완료 범위는 실제 구현 · 발표 이슈 참조

LOG DE-IDENTIFICATION AGENT

LLM API | Node HTTP | 개발 범위 · 묶음 질문기

로그 비식별화 · 공개 수준(A~D) 질문 생성

기업 A 사내 원본 로그
오류 로그 · 현황표 · 운영 메모

→

문맥 단서 · 민감도 분리
함수명·단가·건수 클러스터링

→

공개 수준(A~D) 질문 UI
사실만·추이만·마스킹·비율

AI 활용: LLM API · ModelClient HTTP 호출

직접 개발: JSON Schema 유사 단서 묶음 질문기

APPROVED-FACT DRAFTING AGENT

호환 LLM | TypeScript | 개발 범위 · 동시 갱신 엔진

원문 격리 초안 작성 · 본문·표 동시 갱신

승인 FactPack 입력
승인된 A~D 허용 사실만 전달

→

선택 기준 맞춤 초안 생성
실제 수치 가림 · 추이·비율 변환

→

본문·표·설명 동시 갱신
본문·표 동기화 계획

AI 활용: 호환 사내 LLM 교체형 초안 생성

직접 개발: 승인 정보 경계 & 본문·표 동시 갱신 엔진

3-WAY CROSS-CHECK & SKILL AGENT

LLM 검토 | 격리 계획 | 개발 범위 · 사내 근거 매핑

해결 스킬 추천 · 3자 대조 및 필수 제약 복원

누락 · 과다 노출 위험
원문 · 선택 기준 · 초안 입력

→

3-Way 대조 · 스킬 추천
유사 문제 분류 · 사내 근거 연결

→

빠진 필수 제약 복원
“기존 접수 채널 유지” 반영

AI 활용: 전체 의미 대조·분류는 후속 계획

직접 개발: 원자료 근거 매핑·제약 복원 계획

RULE REUSE & PUBLIC SKILLPACK

SQLite | node:sqlite | 개발 범위 · Rule 매칭 계획

공개 기준(Rule) 재사용 · 공개 SkillPack 공유 계획

Rule 저장 / 공개 팩 계획
공개 기준 저장 계획

→

scope·grant 대조 계획
목적·상대·자료 조건 대조

→

공개 팩 공유 계획
일치 시 즉시 적용 · 변경 시 재질문

인프라 활용: SQLite · node:sqlite

직접 개발: Skill Repository & 조건부 Rule 매칭 계획

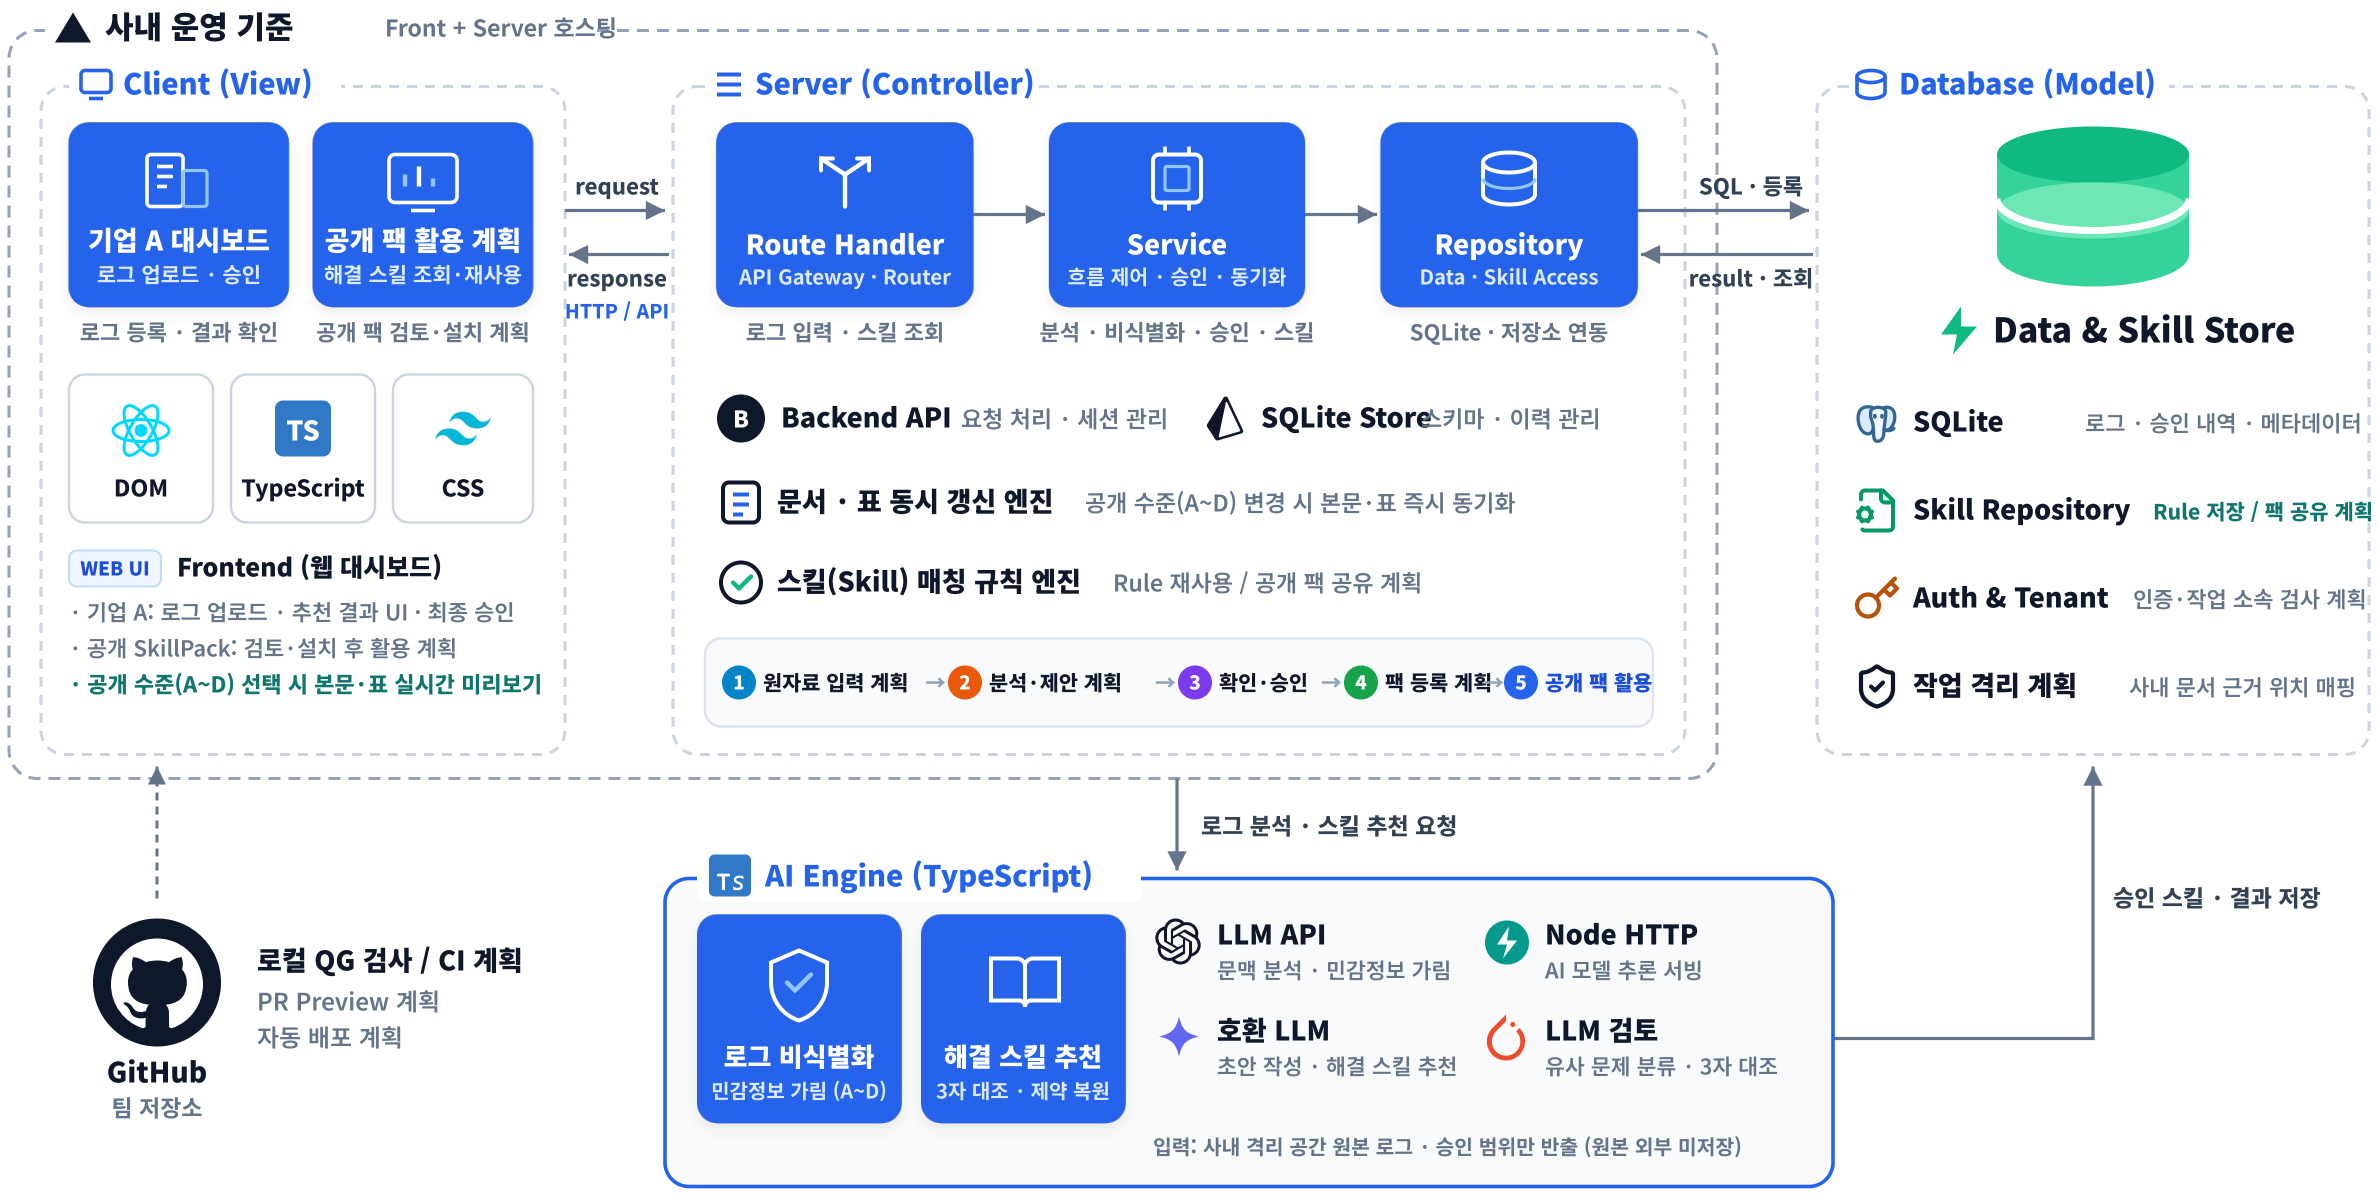
현행 아키텍처 참조 · 구현 상태·미결 사항

현재 연결 스택은 현행 아키텍처 문서 참조 · 분석·질문·전체 대조·Rule 매칭은 후속

작성·검토·팩 연결 구현 / 분석·Rule·동기화 후속

공유 자료 준비 아키텍처 · 현행 기반과 후속 계획

설계 목표·후속 계획 포함 · 현재 완료 범위는 실제 구현 · 발표 이슈 참조



서비스 차별점

설계 목표·후속 계획 포함 · 현재 완료 범위는 실제 구현 · 발표 이슈 참조

구분	개인정보 마스킹 · 보안 통제 Limina · Private AI · MS Purview	합성 데이터 · 기술지원 도구 Tonic · Jam · StepStitch · Cloudflare	일반 AI + 실무자 수작업 프롬프트 지시 + 직접 가림 · 대조	**SafeHandoff** 우리 서비스
주 대상 자료	개인정보 항목 · 보안 라벨 문서	DB 테이블 · 브라우저 버그 기록	사내 로그 · 운영 표 · 문의 초안	**기술 문의(오류·정산)부터 일반 내부 자료(자문·운영)까지**
공개 범위 설정	고정 항목 마스킹 또는 외부 접근 차단	합성 데이터 생성 또는 로그 표식 정리	매번 지시문 작성 + 사람이 직접 삭제	**공개 수준(A~D) 4단계 선택 (사실만 · 추이만 · 마스킹 · 비율)**
원본 처리 방식	원문 속 단어만 치환 (업무 맥락·함수명 잔존)	데이터·화면만 별도 추출 (문의 본문과 분리됨)	외부 AI에 원본 먼저 전송 (유출 위험 발생)	**인터넷 차단 사내 공간 + 허용 범위로만 새 초안 작성**
★ 조건 변경 시	단어 치환만 수행 (문장·표 연동 없음)	예제·로그만 따로 재생성	본문·표의 숫자를 사람이 일일이 다시 수정	**선택 변경 시 관련된 본문 · 표 · 설명 동시 자동 갱신**
★ 단서 · 제약 보존	일괄 삭제로 문제 해결 단서 손실	버그 기록 위주 (일반 자문·업무 제약 미지원)	빠진 조건과 오류 여부를 담당자가 눈으로 대조	**검토 AI가 빠진 제약 복원 + 새 예제 오류 재현까지 확인**
★ 판단 근거 확인	탐지된 항목만 표시 (블랙박스 필터링)	실행 로그 · 증거 묶음만 제공	담당자 기억과 수동 비교	**문장별 원문 근거 위치 연결 + 공개 이유 문장 제시**
반복 작업 부담	고정 탐지 규칙만 적용 (목적별 조정은 수작업)	수정 사례 참고만 가능	문의 때마다 처음부터 반복	**검증된 기준을 스킬(Skill)로 등록 조건 일치 시 자동 재사용**

기대효과

설계 목표·후속 계획 포함 · 현재 완료 범위는 실제 구현 · 발표 이슈 참조

① 자료 준비 시간 / 부담

지금

수작업 의존

직접 가리고 본문·표 숫자를 일일이 대조

문의 때마다 처음부터 반복 · 대응 지연

SafeHandoff

원클릭 갱신

공개 수준(A~D) 선택 시 본문·표 동시 반영

스킬(Skill) 자동화로 반복 감축

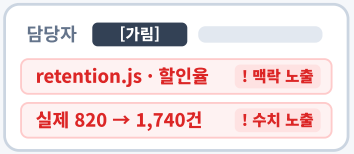
같은 목적·상대·조건이면 저장한 기준 즉시 적용

② 민감 정보 및 맥락 보호

지금

민감 단서 잔존

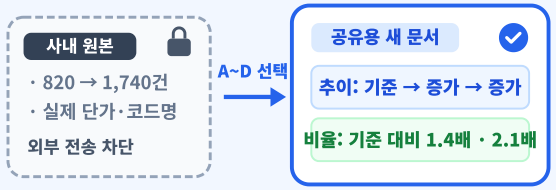
이름만 가려도 함수명·관계·단가로 노출



SafeHandoff

필요 범위만 공개

사실·추이·마스킹·비율로 새 문서 작성



원문 공유 대비 불필요한 내부 정보 노출 축소

③ 파급 손실 및 누락 방어

지금

사후 수습

필수 조건·단서 누락 후 재질문 반복

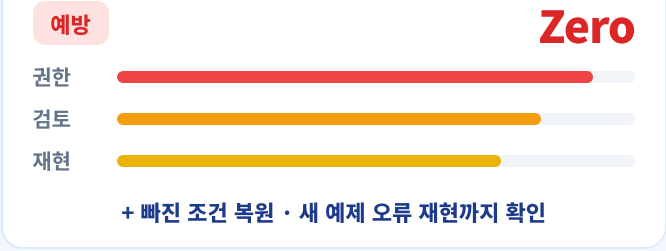
● 필수 제약 · 오류 단서 손실

"기존 접수 채널 유지" 누락 · 추가 자료 재요청

SafeHandoff

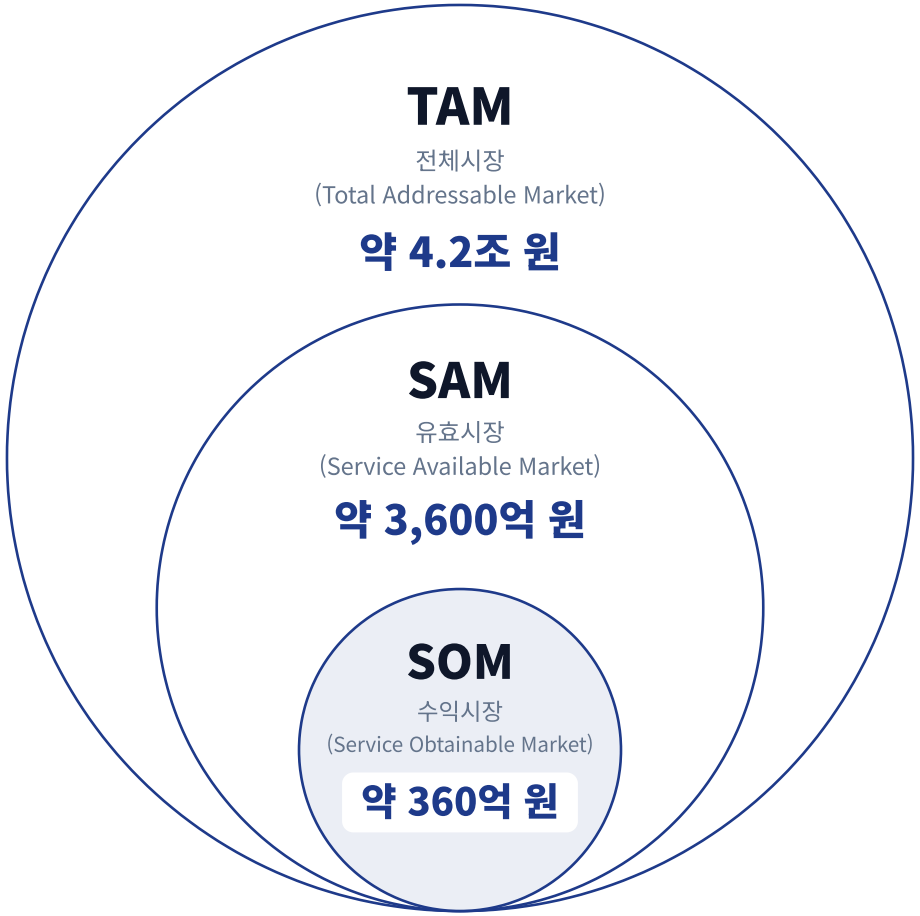
사전 차단 · 검증

사내 공간 분리 및 작성·검토 AI 이중 확인



서비스 확장 계획: 타겟 시장(TAM-SAM-SOM) 로드맵

해커톤 시장성 가설 · 확정 BM/로드맵 아님 · ISSUES PRES-08 참조



Phase 1. 단기 (SOM) **사내 AI·망분리 환경을 운영 중인 국내 IT·금융 기업**

규모: 360억 원

- **타겟 및 적용:** 기존 사내 AI·경량 공개 모델(sLLM)에 추가 장비 없이 즉시 연결 (약 1.5만 개사)
- **근거 및 개발:** 15,000개사 × 연 240만 원 (월 20만 원 구독) · 공개 수준(A~D) 초안·검토·스킬 자동화

Phase 2. 중기 (SAM) **외부 기술 문의·자문이 빈번한 국내 전체 중소·중견기업**

규모: 3,600억 원

- **타겟 및 확산:** 개발팀(오픈소스 제보)부터 운영·재무팀(정산·컨설팅 자문)까지 전사 확산 (약 15만 개사)
- **근거 및 개발:** 150,000개사 × 연 240만 원 · 제품별 제보 양식팩, 문맥 예외 판별, 대용량 고속 검색

Phase 3. 장기 (TAM) **글로벌 기업용 AI 데이터 보안 · 외부 협업 SaaS 시장**

규모: 약 4.2조 원

- **타겟 및 확장:** 아시아 및 글로벌 B2B 기술지원 · 기업용 생성형 AI 반출 통제(DLP) 시장 확장
- **근거 및 개발:** 국내 유효 시장의 약 12배 규모 환산 · 합성 예제 자동 실행 검증 및 지원 티켓 원스톱 연동

* 시장 규모 추정: 기업용 SaaS 구독료(월 20만 원) 기준 하향식(Bottom-up) 재산출 / 국내 ICT·정보보호 기업 통계 및 글로벌 AI 보안(DLP) 시장 기준

확장 원칙: 공개 범위는 항상 사용자가 결정 · 준비된 업무부터 단계적 연결

팀원 소개 및 역할 분담

담당 개발 범위 · 개별 기능 완료는 실제 구현 · 발표 이슈 참조

TEAM · 지피한테물어봐

팀장 · 백엔드

김병철

팀 총괄 · 보안 격리 백엔드 설계

담당 업무 및 개발 범위

- **프로젝트 총괄 및 아키텍처:** 사내 작업 공간 원문 처리 경계 구조 및 핵심 API 서버 설계·구현
- **사내 근거 매핑 엔진 개발:** 반출용 초안 문장과 사내 원본 문서(운영메모.md) 위치 연결 백엔드 구현
- **시스템 통합 및 품질 검증:** 멀티 에이전트 파이프라인과 백엔드 상태 동기화 총괄

Team Lead | Backend Arch

AI 서빙

김민성

멀티 에이전트 · AI 추론 서빙

담당 업무 및 개발 범위

- **3단계 AI 서빙 파이프라인:** 분석·작성·검토 에이전트 추론 서빙 및 응답 지연 최적화 구현
- **모델 교체형 추론 인터페이스:** 사내 LLM 및 경량 공개 모델(sLLM) 즉시 연결·교체 서빙 구조 개발
- **JSON Schema 제어 및 검증:** 유사 항목 묶음 질문(A~D) 및 3-Way 의미 대조 추론 안정화

AI Serving | LLM Agent

백엔드

임재홍

비식별 규칙 엔진 · 스킬 저장소 서버

담당 업무 및 개발 범위

- **공개 수준(A~D) 변환 엔진 개발:** 실제 수치·단가를 선택한 공개 수준(추이·비율·마스킹)으로 안전하게 변환하는 백엔드 구현
- **조건부 스킬(Skill) 엔진 구현:** 검증된 가림 기준 저장 및 '목적·수신처·조건' 일치 판별 백엔드 개발
- **누락 제약 복원 로직:** 필수 업무 제약("기존 접수 채널 유지") 자동 탐지 및 복원 처리

Backend Dev | Rule & Skill

풀스택

맹주영

워크스페이스 UI · 동시 갱신 연동

담당 업무 및 개발 범위

- **5단계 워크스페이스 구현:** 자료 입력 → 공개 수준(A~D) 선택 → 직접 입력(D) → 최종 확인 풀스택 개발
- **본문·표·설명 동시 갱신:** A~D 선택 변경 시 연결된 문장·표·설명을 실시간 동기화하고 잔존 숫자를 제거
- **공유본 반출 인터페이스:** 내부 근거 분리 표시 및 최종 결과 복사·다운로드 기능 개발 계획

Full-Stack | Sync UI/API

PM

이상혁

서비스 기획 총괄 · UX 및 시장 전략

담당 업무 및 개발 범위

- **문제 정의 및 도메인 기획:** 기업 보안 사고 사례 조사 및 타겟 페르소나·유즈케이스·요구사항 정의
- **공개 수준(A~D) UX 설계:** 실무자 친화적 4단계 공개 기준(사실만·추이만·마스킹·비율) 및 플로우 설계
- **확장 전략 및 스토리라인:** 타겟 시장(TAM-SAM-SOM) 로드맵, 서비스 차별점 및 발표 구성 총괄

Product PM | UX & Strategy

협업 및 직접 개발 원칙 서비스 기획(PM)부터 AI 서빙, 보안·스킬 백엔드, 동시 갱신 풀스택 워크스페이스까지 전 과정의 담당 범위이며 항목별 완료 여부는 별도 확인